

ESTIMAÇÃO DE ALTURA DE PEDESTRES EM IMAGENS MONOCULARES: COMPARAÇÃO ENTRE ABORDAGEM GEOMÉTRICA CLÁSSICA E ESTIMAÇÃO DE PROFUNDIDADE COM METRIC3D V2

ADAM PEREIRA BIDIAKI¹, FÁBIO AUGUSTO MENOCCI CAPPABIANCO²

¹ Discente do Programa de Pós-Graduação em Ciência da Computação, Universidade Federal de São Paulo, Campus São José dos Campos, adambidiaki1@gmail.com

² Docente do Programa de Pós-Graduação em Ciência da Computação, Universidade Federal de São Paulo, Campus São José dos Campos, cappabianco@unifesp.br

Área de conhecimento (Tabela CNPq): 1.03.03.05-7 Processamento Gráfico

RESUMO

Este trabalho apresenta um estudo comparativo entre duas abordagens para estimação de altura de pedestres a partir de imagens monoculares. A primeira baseia-se na geometria projetiva, que utiliza pontos de fuga para inferir medidas métricas diretamente na imagem. A segunda emprega o modelo Metric3D V2 para estimação de profundidade, combinado aos parâmetros intrínsecos da câmera para reconstrução tridimensional dos pontos de interesse. Para a avaliação, foram selecionadas manualmente 55 imagens do conjunto de dados KITTI Vision Benchmark Suite, correspondentes a uma mesma cena e capturadas pela mesma câmera, mantendo constantes seus parâmetros intrínsecos e seu posicionamento em todas as imagens analisadas. Os resultados indicam uma superioridade da abordagem baseada no Metric3D V2, que obteve erro absoluto médio (MAE) de 0,14 metros e erro percentual absoluto médio (MAPE) de 7,63%, enquanto o método geométrico apresentou um MAE de 0,64 metros e um MAPE de 35,13%. Esses resultados evidenciam o potencial dos modelos de estimação de profundidade para a obtenção de estimativas de altura mais precisas em comparação às abordagens geométricas clássicas.

1. INTRODUÇÃO

A estimação de medidas métricas a partir de imagens monoculares representa um dos principais desafios da visão computacional, uma vez que busca recuperar informações tridimensionais a partir de uma única imagem. A obtenção dessas medidas é fundamental para diversas tarefas que envolvem a compreensão geométrica da cena, como a estimação de dimensões, distâncias e posições de objetos no espaço.

A principal dificuldade dessa tarefa decorre do processo de formação da imagem. Em uma câmera monocular, a projeção perspectiva faz com que a informação de profundidade seja perdida, tornando ambígua a relação entre o tamanho aparente de um objeto na imagem e suas dimensões reais. Dessa forma, a obtenção de medidas métricas depende da incorporação de informações adicionais, seja por meio de restrições geométricas da cena ou por técnicas capazes de inferir profundidade a partir do conteúdo visual.

Ao longo das últimas décadas, diferentes estratégias foram propostas para contornar essa limitação. As abordagens clássicas baseiam-se em princípios da geometria projetiva, explorando propriedades como pontos de fuga, planaridade do solo e relações de paralelismo para estimar dimensões

reais dos objetos (CRIMINISI; REID; ZISSERMAN, 2000; HARTLEY; ZISSERMAN, 2004; HEUVEL, 1998; LIEBOWITZ; ZISSERMAN, 1998). Mais recentemente, os avanços em aprendizado profundo possibilitaram o desenvolvimento de modelos capazes de estimar mapas densos de profundidade monocular, aprendendo relações tridimensionais diretamente a partir de grandes volumes de dados (RANFTL; BOCHKOVSKIY; KOLTUN, 2021; RANFTL *et al.*, 2022).

Embora essas abordagens sejam baseadas em princípios bastante distintos, ambas têm como objetivo estimar informações métricas a partir de imagens monoculares. Assim, a comparação entre métodos geométricos e modelos baseados em aprendizado profundo permite avaliar suas características, identificar suas principais limitações e analisar seu desempenho sob as mesmas condições experimentais.

Nesse contexto, este trabalho compara o método geométrico proposto por Criminisi (1999), baseado na utilização de pontos de fuga para estimação de altura, com o Metric3D V2, um modelo de estimação de profundidade baseado em *Vision Transformers* (ViT), desenvolvido como evolução do modelo Metric3D originalmente proposto por Yin *et al.* (2023) e posteriormente ampliado por Hu *et al.* (2024). Ambos os métodos foram avaliados utilizando imagens do conjunto de dados KITTI Vision Benchmark Suite, mantendo constantes os parâmetros intrínsecos e a pose da câmera durante todos os experimentos. Os resultados obtidos permitem comparar quantitativamente o desempenho das duas abordagens e discutir suas vantagens e limitações na tarefa de estimação da altura de pedestres.

2. ESTIMAÇÃO DE ALTURA EM IMAGENS MONOCULARES

A estimação de altura em imagens monoculares pode ser realizada por diferentes estratégias, que se distinguem principalmente pela forma como recuperam informações tridimensionais a partir de uma única imagem. De maneira geral, essas estratégias podem ser divididas em duas categorias. A primeira compreende métodos baseados em geometria projetiva, que utilizam restrições geométricas da cena e do modelo de câmera para inferir medidas métricas. A segunda inclui abordagens baseadas em aprendizado profundo, que estimam mapas de profundidade a partir de grandes conjuntos de dados e utilizam essas informações para reconstruir a geometria tridimensional da cena. Nesta seção são apresentadas as duas abordagens avaliadas neste trabalho.

2.1. Abordagem baseada em geometria projetiva

O método proposto por Criminisi (1999) permite estimar medidas métricas diretamente em imagens monoculares utilizando conceitos da geometria projetiva. A abordagem explora propriedades como pontos de fuga e linha do horizonte para estabelecer relações entre as dimensões aparentes dos objetos na imagem e suas dimensões reais.

Para a estimação de altura, o método utiliza um objeto de referência com altura conhecida e assume que os objetos analisados estão apoiados sobre o mesmo plano e orientados verticalmente, como ilustrado na Figura 1. A partir dessas informações, relações de proporcionalidade permitem compensar os efeitos da perspectiva e estimar a altura do objeto de interesse.

Embora seja capaz de estimar medidas métricas utilizando apenas informações geométricas da imagem, o método depende da correta identificação dos pontos de referência e do cumprimento das hipóteses geométricas adotadas. Dessa forma, pequenas imprecisões na estimação do ponto de fuga ou desvios em relação às condições ideais da cena podem comprometer significativamente a precisão das estimativas.

Figura 1. Estimação de altura baseada em geometria projetiva.



Fonte: CRIMINISI (1999).

2.2. Abordagem baseada em aprendizado profundo

O Metric3D V2 representa uma abordagem baseada em aprendizado profundo para estimação monocular de profundidade. O modelo constitui uma evolução do Metric3D originalmente proposto por Yin *et al.* (2023), incorporando melhorias arquiteturais e de generalização apresentadas por Hu *et al.* (2024). Diferentemente de modelos que produzem apenas profundidade relativa, o Metric3D V2 utiliza os parâmetros intrínsecos da câmera durante a inferência para estimar mapas de profundidade em escala métrica, permitindo recuperar informações tridimensionais da cena a partir de uma única imagem RGB. A Figura 2 apresenta um exemplo de mapa de profundidade gerado pelo modelo.

A partir do mapa de profundidade gerado pelo modelo e dos parâmetros intrínsecos da câmera, é possível reconstruir as coordenadas tridimensionais dos pontos da imagem e, consequentemente, obter estimativas métricas de distâncias e dimensões dos objetos presentes na cena. Essa característica permite que o Metric3D V2 seja aplicado em tarefas de reconstrução tridimensional e medição de objetos, reduzindo a dependência de restrições geométricas explícitas da cena, como a estimação de pontos de fuga ou a identificação de planos de referência. Além disso, o treinamento sobre múltiplos conjuntos de dados contribui para aumentar a capacidade de generalização do modelo em diferentes cenários, característica considerada essencial para métodos de estimação de profundidade monocular (RANFTL *et al.*, 2022).

Figura 2. Mapa de profundidade gerado pelo Metric3D V2.



Fonte: HU *et al.* (2024).

3. METODOLOGIA

Os experimentos foram conduzidos sobre imagens do conjunto de dados KITTI Vision Benchmark Suite, especificamente o subconjunto *Object Detection Evaluation 2012*. Foram selecionadas manualmente 55 imagens de uma mesma cena, capturadas com a mesma câmera, mantendo idênticos seus parâmetros intrínsecos e posicionamento em todas as imagens avaliadas. As imagens foram escolhidas por apresentar apenas um pedestre por imagem, o que simplifica o processo de anotação e reduz ambiguidades nas medições, a Figura 3 apresenta uma das imagens escolhidas. Os rótulos do conjunto de dados fornecem, entre outras informações, a altura real dos pedestres presentes nas imagens, que foram utilizadas como *ground truth* neste estudo.


Figura 3. Cena escolhida para realizar os experimentos.



Fonte: GEIGER, LENZ e URTASUN (2012).

Para a implementação da abordagem geométrica, o ponto de fuga vertical foi estimado automaticamente na primeira imagem da sequência por meio da detecção, do agrupamento e da filtragem das linhas convergentes. Em seguida, o ponto de fuga e a altura conhecida do pedestre de referência foram armazenados em um arquivo de configuração no formato *.json*, permitindo que as mesmas informações de calibração fossem utilizadas em todas as imagens subsequentes. Durante a estimação, foram selecionados apenas os pontos correspondentes à base e ao topo do pedestre, sendo a altura calculada automaticamente pelo método de Criminisi. A Figura 4 apresenta as linhas detectadas e o ponto de fuga estimado.

Figura 4. Linhas detectadas e ponto de fuga estimado para a abordagem geométrica



Fonte: Autores (2026).

Para a abordagem baseada no Metric3D V2, o mapa de profundidade foi gerado individualmente para cada imagem utilizando o modelo “*metric3d_vit_small*”. A partir da primeira imagem da sequência, foi determinado um fator de escala com base no mesmo pedestre de referência da abordagem geométrica. Esse fator, juntamente com os parâmetros intrínsecos da câmera, foi armazenado em um arquivo de configuração no formato *.json* e utilizado no processamento das demais imagens. Durante a estimação,

selecionou-se um ponto sobre o pedestre para obter sua profundidade de referência e, em seguida, os pontos correspondentes à base e ao topo do indivíduo. Com essas informações, as coordenadas tridimensionais dos pontos foram reconstruídas, permitindo o cálculo automático da altura. A Figura 5 apresenta o mapa de profundidade estimado para a cena utilizada no experimento.

Figura 5. Mapa de profundidade estimado para a cena utilizada no experimento



Fonte: Autores (2026).

A etapa de avaliação teve como objetivo quantificar a precisão das duas abordagens de estimação de altura consideradas neste trabalho. Para isso, as alturas estimadas por cada método foram comparadas com os respectivos valores reais de altura, utilizando métricas estatísticas amplamente empregadas na avaliação de métodos de estimação.

As métricas utilizadas foram o erro absoluto médio (MAE) e o erro percentual absoluto médio (MAPE). O MAE expressa o erro médio das estimativas em unidades de medida (metros), enquanto o MAPE representa o erro médio relativo em termos percentuais, permitindo comparar o desempenho das abordagens de forma independente da escala das alturas avaliadas.

4. RESULTADOS E DISCUSSÃO

Neste capítulo são apresentados e discutidos os resultados obtidos pelas duas abordagens de estimação de altura avaliadas neste trabalho e discute seus principais comportamentos diante do conjunto de imagens analisado. Inicialmente são comparadas as métricas quantitativas de desempenho e, posteriormente, são analisadas a distribuição dos erros e as limitações observadas em cada abordagem.

A Tabela 1. Desempenho das abordagens avaliadas apresenta o desempenho global das duas abordagens considerando as 54 imagens utilizadas nos experimentos.

Tabela 1. Desempenho das abordagens avaliadas


Abordagem	MAE	MAPE
Geométrica	0,64	35,14%
Metric3D V2	0,14	7,62%

Os resultados evidenciam uma vantagem consistente da abordagem baseada no Metric3D V2 em todas as métricas analisadas. A comparação dos valores apresentados na Tabela 1 mostra que o método geométrico alcançou um MAE de 0,64 metros, enquanto a abordagem baseada no Metric3D V2 apresentou um MAE de 0,14 metros, correspondendo a uma redução aproximada de 78% no erro médio. De forma análoga, o MAPE foi reduzido de 35,13% para 7,63%, indicando uma melhora significativa na precisão das estimativas.

Além da melhora observada nas métricas médias, o método geométrico apresentou um erro absoluto máximo de 1,29 metros, enquanto o Metric3D V2 atingiu um erro máximo de 0,81 metros. Embora ambos os métodos tenham apresentado casos de maior discrepância, os resultados indicam que a abordagem baseada em profundidade monocular manteve desempenho mais estável mesmo em situações menos favoráveis

A Figura 6 apresenta a distribuição dos erros absolutos obtidos pelas duas abordagens. Observa-se que o método geométrico apresentou maior dispersão dos erros, com maior concentração de estimativas em faixas de erro elevadas. Em contrapartida, o Metric3D V2 concentrou a maior parte das estimativas em erros reduzidos, evidenciando menor variabilidade entre as imagens avaliadas e maior consistência em relação às alturas reais.


Figura 6. Distribuição dos erros absolutos obtidos pelas duas abordagens



Fonte: Autores (2026).

Comportamento semelhante pode ser observado na Figura 7, que apresenta a distribuição dos erros relativos. Enquanto o método geométrico apresentou maior variabilidade percentual entre as estimativas, a abordagem baseada no Metric3D V2 concentrou a maior parte dos resultados em baixos percentuais de erro, confirmando o desempenho superior já observado nas métricas globais.

Figura 7. Distribuição dos erros relativos obtidos pelas duas abordagens



Fonte: Autores (2026).

Os resultados obtidos refletem as diferenças entre os princípios de funcionamento das duas abordagens. O método geométrico fundamenta-se em relações projetivas e depende da validade das hipóteses geométricas adotadas, bem como da correta definição dos pontos utilizados durante a estimação. Em consequência, sua precisão tende a ser mais sensível às características da cena e à seleção desses pontos, o que pode resultar em maior variabilidade nas estimativas de altura.

Por outro lado, o Metric3D V2 utiliza mapas de profundidade estimados por aprendizado profundo para recuperar informações tridimensionais da cena, reduzindo a dependência de restrições geométricas explícitas. Como consequência, pequenas variações na seleção dos pontos de interesse

exercem menor influência sobre a altura estimada, contribuindo para a redução dos erros e para uma maior estabilidade entre diferentes imagens.

Embora o Metric3D V2 tenha apresentado desempenho superior na maior parte das amostras, foram identificadas algumas imagens em que seus erros aumentaram significativamente. Esses resultados evidenciam que, embora mais preciso e consistente, o modelo também apresenta limitações em determinadas situações. De forma semelhante, também foram observadas situações em que o método geométrico apresentou desempenho comparável ao do Metric3D V2, demonstrando que, quando aplicado em condições favoráveis, é capaz de fornecer estimativas de altura com elevada precisão.

De maneira geral, os resultados obtidos indicam que a abordagem baseada no Metric3D V2 apresentou maior robustez para a tarefa de estimação de altura nas condições avaliadas. Além de reduzir significativamente os erros médios, o método apresentou menor dispersão das estimativas e maior consistência ao longo de todo o conjunto de imagens analisado.

5. CONCLUSÃO

Este trabalho apresentou uma comparação entre duas abordagens para estimação de altura de pedestres em imagens monoculares: o método geométrico proposto por Criminisi (1999), baseado em relações projetivas, e o Metric3D V2, um modelo de estimação de profundidade métrica baseado em aprendizado profundo. A avaliação realizada sobre 54 imagens do conjunto de dados KITTI Vision Benchmark Suite demonstrou uma superioridade do Metric3D V2, que alcançou um MAE de 0,14 metros e um MAPE de 7,63%, enquanto a abordagem geométrica obteve um MAE de 0,64 metros e um MAPE de 35,13%.

A análise dos resultados mostrou que o método geométrico é fortemente influenciado pela precisão das referências utilizadas durante o processo de estimação, tornando-o mais sensível a variações de perspectiva e às características da cena. Em contrapartida, o Metric3D V2 apresentou estimativas mais precisas e consistentes, evidenciando o potencial dos modelos de estimação de profundidade para aplicações de estimação de altura.

Como limitações deste estudo, destaca-se a avaliação realizada em um único conjunto de dados e com um número restrito de imagens. Dessa forma, trabalhos futuros podem investigar o desempenho das abordagens em outros cenários e bases de dados, incluindo diferentes condições de iluminação, perspectiva e distância entre a câmera e os pedestres. Além disso, uma análise detalhada dos casos em que o Metric3D V2 apresentou erros mais elevados pode contribuir para uma melhor compreensão das limitações do modelo.

REFERÊNCIAS

CRIMINISI, A. **Accurate Visual Metrology from Single and Multiple Uncalibrated Images**. Universidade de Oxford. Oxford, p. 210. 1999.

CRIMINISI, A.; REID, I.; ZISSERMAN, A. Single View Metrology. **Proceedings of the Seventh IEEE International Conference on Computer Vision**, 2000. DOI: 10.1109/ICCV.1999.791253.

GEIGER, A.; LENZ, P.; URTASUN, R. Are we ready for Autonomous Driving? The KITTI Vision Benchmark Suite. **2012 IEEE Conference on Computer Vision and Pattern Recognition**, 2012. DOI: 10.1109/CVPR.2012.6248074.

HARTLEY, R.; ZISSERMAN, A. **Multiple View Geometry in Computer Vision**. 2. ed. Cambridge: Cambridge University Press, 2004.

HEUVEL, F. 3D reconstruction from a single image using geometric constraints. **ISPRS Journal of Photogrammetry and Remote Sensing**, v. 53, n. 6, p. 354 - 368, 1998. DOI: 10.1016/S0924-2716(98)00019-7.

HU, M.; YIN, W.; ZHANG, C.; CAI, Z.; LONG, X.; CHEN, H. Metric3D V2: A Versatile Monocular Geometric Foundation Model for Zero-Shot Metric Depth and Surface Normal Estimation. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 46, n. 12, p. 10579 - 10596, 2024. DOI: 10.1109/TPAMI.2024.3444912.

LIEBOWITZ, D.; ZISSERMAN, A. Metric Rectification for Perspective Images of Planes. **Proceedings. 1998 IEEE Computer Society Conference on Computer Vision and Pattern Recognition**, 1998. DOI: 10.1109/CVPR.1998.698649.

RANFTL, R.; BOCHKOVSKIY, A.; KOLTUN, V. Vision Transformers for Dense Prediction. **2021 IEEE/CVF International Conference on Computer Vision (ICCV)**, 2021. DOI: 10.1109/ICCV48922.2021.01196.

RANFTL, R.; LASINGER, K.; HAFNER, D.; SCHINDLER, K.; KOLTUN, V. Towards Robust Monocular Depth Estimation: Mixing Datasets for Zero-shot Cross-dataset Transfer. **IEEE Transactions on Pattern Analysis and Machine Intelligence**, v. 44, n. 3, p. 1623 - 1637, 2022. DOI: 10.1109/TPAMI.2020.3019967.

YIN, W.; ZHANG, C.; CHEN, H.; CAI, Z.; YU, G.; WANG, K.; CHEN, X.; SHEN, C. Metric3D: Towards Zero-shot Metric 3D Prediction from a Single Image. **2023 IEEE/CVF International Conference on Computer Vision (ICCV)**, 2023. DOI: 10.1109/ICCV51070.2023.00830.